

# MBA<sup>+</sup>

# MBA EM BIG DATA (DATA SCIENCE)



# MBA<sup>+</sup>

#### INGESTÃO DE DADOS NiFi

Prof. Thiago Nascimento Nogueira tnnogueira@gmail.com

Linked-in: https://www.linkedin.com/in/thnogueira



## NiFi

## Características





- "Canivete suiço" para ingestão de dados
- Utilizado em projetos qua não envolvem necessariamente hadoop
- Interface Web
  - Experiência integrada entre desenho, controle, feedback e monitoria
- Altamente configurável
  - Tolerante a falhas com garantia de entrega
  - Baixa latência e alto throughput
  - Priorização dinâmica
  - Fluxo pode ser alterado em tempo de execução
  - "Back pressure"

### Características



- Data Provenance (Procedência de dados)
  - Rastreamento do dataflow, do início ao fim
- Desenhado para extensibilidade
  - Permite desenvolvimento de processors customizados
  - Rápido desenvolvimento e testes efetivos
- Segurança
  - SSL, SSH, HTTPS, criptografia de conteúdo, etc..
  - · Autorização Multi-tenant e autorização / política de gerenciamento interna

## **Conceitos Centrais**



- FlowFile Objeto que se move através do fluxo onde, para cada FlowFile, o NiFI mantém um mapeamento key/value com atributos e seu conteúdo associado, com zero ou mais bytes
- Processadores de Fluxo Realizam o trabalho de fato. Realizam alguma combinação entre roteamento de dados, transformação, ou mediação entre sistemas. Possuem acesso aos atributos e conteúdos do FlowFile
- Conexão Promovem as ligações entre os processadores. Funcionam como filas e permitem que vários processadores interajam de diferentes maneiras
  - Podem ser priorizadas dinamicamente
  - Possuem limites máximos de carga, permitindo controle tipo "back pressure"
- Controlador de Fluxo Mantém o controle de como os processos se conectam e gerencia os recursos de cada processo
- **Grupo de Processos** Agrupamento lógico de conjunto de processos.


### **Arquitetura**



- WebServer Hospeda os comando NiFi baseados em http e API de controle
- Flow Controller Cérebro da operação. Provê as threads para que os processos rodem e gerencia o agendamento de quando o processo recebe os recursos para executar
- FlowFile Repository Lugar onde o NiFI mantém as informações sobre os estados dos FlowFiles
- Content Repository Lugar o são armazenados os conteúdos do FlowFile em execução
- Provenance Repository Local onde os dados de eventos de data provenance são armazenados


### Arquitetura






### Tela Inicial






### Componentes





### Componentes






#### Adicionando um Processor







## Criando uma conexão 🔕





Create Connection			
DETAILS SETTINGS Name	Available Prioritizers 🛭		
Name	FirstInFirstOutPrioritizer		
Id No value set	NewestFlowFileFirstPrioritizer		
FlowFile Expiration ②	OldestFlowFileFirstPrioritizer		
0 sec	PriorityAttributePrioritizer		
Back Pressure Object Threshold  10000	Selected Prioritizers ②		
Back Pressure Data Size Threshold ②			
1 GB			
		CANCEL	ADD





#### NiFi Data Provenance

Displaying 193 of 193

Oldest event available: 07/18/2016 11:09:24 EDT

Showing the most recent events.

Filter	by compo	nent n 🗸					a
	Date/Time	Туре	FlowFile Uuid 🔺	Size	Component Name	Component Type	
0	07/18/2016 11:09:57.574 EDT	CONTENT_MODIFIED	0fe67e3c-9408-4eff-8772-252f1f4b399f	2.91 KB	ExecuteSQL	ExecuteSQL	&→
0	07/18/2016 11:10:04.224 EDT	ATTRIBUTES_MODIFIED	0fe67e3c-9408-4eff-8772-252f1f4b399f	2.91 KB	UpdateAttribute	UpdateAttribute	& →
0	07/18/2016 11:10:13.713 EDT	CONTENT_MODIFIED	0fe67e3c-9408-4eff-8772-252f1f4b399f	5.76 KB	ConvertAvroToORC	ConvertAvroToORC	& →
0	07/18/2016 11:10:40.352 EDT	SEND	0fe67e3c-9408-4eff-8772-252f1f4b399f	5.76 KB	PutHDFS	PutHDFS	&→
0	07/18/2016 11:10:40.352 EDT	ATTRIBUTES_MODIFIED	0fe67e3c-9408-4eff-8772-252f1f4b399f	5.76 KB	PutHDFS	PutHDFS	&→
0	07/18/2016 11:11:25.506 EDT	CONTENT_MODIFIED	0fe67e3c-9408-4eff-8772-252f1f4b399f	422 bytes	ReplaceText	ReplaceText	&→
0	07/18/2016 11:11:48.435 EDT	SEND	0fe67e3c-9408-4eff-8772-252f1f4b399f	422 bytes	PutHiveQL	PutHiveQL	&→
9	07/18/2016 11:11:48.871 EDT	DROP	0fe67e3c-9408-4eff-8772-252f1f4b399f	422 bytes	PutHiveQL	PutHiveQL	&-
0	07/18/2016 11:09:57.541 EDT	CONTENT_MODIFIED	1b105de2-eb64-4ff1-b465-4fd8844da437	2.88 KB	ExecuteSQL	ExecuteSQL	& →
0	07/18/2016 11:10:04.224 EDT	ATTRIBUTES_MODIFIED	1b105de2-eb64-4ff1-b465-4fd8844da437	2.88 KB	UpdateAttribute	UpdateAttribute	&→
0	07/18/2016 11:10:13.657 EDT	CONTENT_MODIFIED	1b105de2-eb64-4ff1-b465-4fd8844da437	5.77 KB	ConvertAvroToORC	ConvertAvroToORC	&-
0	07/18/2016 11:10:40.162 EDT	SEND	1b105de2-eb64-4ff1-b465-4fd8844da437	5.77 KB	PutHDFS	PutHDFS	& →
0	07/18/2016 11:10:40.163 EDT	ATTRIBUTES_MODIFIED	1b105de2-eb64-4ff1-b465-4fd8844da437	5.77 KB	PutHDFS	PutHDFS	& →
0	07/18/2016 11:11:25.505 EDT	CONTENT_MODIFIED	1b105de2-eb64-4ff1-b465-4fd8844da437	422 bytes	ReplaceText	ReplaceText	& <del>-</del>
0	07/18/2016 11:11:46.354 EDT	SEND	1b105de2-eb64-4ff1-b465-4fd8844da437	422 bytes	PutHiveQL	PutHiveQL	&→
0	07/18/2016 11:11:48.871 EDT	DROP	1b105de2-eb64-4ff1-b465-4fd8844da437	422 bytes	PutHiveQL	PutHiveQL	&→
9	07/18/2016 11:09:57.567 EDT	CONTENT_MODIFIED	213f984e-e355-42a6-8632-78e1bc37bacf	2.9 KB	ExecuteSQL	ExecuteSQL	& <del>-</del>
0	07/18/2016 11:10:04.224 EDT	ATTRIBUTES_MODIFIED	213f984e-e355-42a6-8632-78e1bc37bacf	2.9 KB	UpdateAttribute	UpdateAttribute	% →
0	07/18/2016 11:10:13.699 EDT	CONTENT_MODIFIED	213f984e-e355-42a6-8632-78e1bc37bacf	5.76 KB	ConvertAvroToORC	ConvertAvroToORC	% →
A	07/10/2016 11:10:40 200 FDT	CENID	010f0040 and 40ak 0600 70a1ba07baaf	E 74 MD	D.+LIDEC	D. #LIDEC	0 _,





#### **Provenance Event**

DETAILS

ATTRIBUTES

CONTENT

Time

07/29/2016 00:58:44.829 UTC

**Event Duration** 

No value set

Lineage Duration

00:00:00.203

Type

ATTRIBUTES\_MODIFIED

FlowFile Uuid

62d2161f-0b2a-4b2a-a552-ab617bef3811

File Size

1.1 KB

Component Id

7bba4f68-2861-3a12-aac6-60f12e11e215

Component Name

EvaluateJsonPath

Component Type

Parent FlowFiles (0)

No parents

Child FlowFiles (0)

No children



#### **Provenance Event** ATTRIBUTES DETAILS CONTENT **Attribute Values** ■ Show modified attributes only eventType ATTRIBUTES\_MODIFIED No value previously set filename 6320498487869637 newSize 1119 No value previously set oldSize 1119 No value previously set path reporting.task.transaction.id fc9fad99-89f0-4978-a3aa-571bb8b8851b uuid 62d2161f-0b2a-4b2a-a552-ab617bef3811



#### **Provenance Event**

DETAILS **ATTRIBUTES** CONTENT **Input Claim Output Claim** Container Container default default Section Section 918 918 Identifier Identifier 1469753924663-275350 1469753924663-275350 Offset Offset 108834 108834 Size Size 1.1 KB 1.1 KB ♣ DOWNLOAD ♣ DOWNLOAD **O** VIEW **O** VIEW

#### Replay

Connection Id 88970033-a406-33a2-b679-711d04de4a35

### Referências



Gregor Hohpe. Enterprise Integration Patterns [online]. Retrieved: 27 Dec 2014, from: http://www.enterpriseintegrationpatterns.com

Wikipedia. Service Oriented Architecture [online]. Retrieved: 27 Dec 2014, from: http://en.wikipedia.org/wiki/Service-oriented\_architecture

Eric Savitz. Welcome to the API Economy [online]. Forbes.com. Retrieved: 27 Dec 2014, from: http://www.forbes.com/sites/ciocentral/2012/08/29/welcome-to-the-api-economy

Adam Duvander. The rise of the API economy and consumer-led ecosystems [online]. thenextweb.com. Retrieved: 27 Dec 2014, from: http://thenextweb.com/dd/2014/03/28/api-economy

Wikipedia. Internet of Things [online]. Retrieved: 27 Dec 2014, from: http://en.wikipedia.org/wiki/Internet\_of\_Things

Wikipedia. Big Data [online]. Retrieved: 27 Dec 2014, from: http://en.wikipedia.org/wiki/Big\_data

Wikipedia. Flow Based Programming [online]. Retrieved: 28 Dec 2014, from: http://en.wikipedia.org/wiki/Flow-based\_programming#Concepts

Matt Welsh. Berkeley. SEDA: An Architecture for Well-Conditioned, Scalable Internet Services [online]. Retrieved: 18 Jan 2018, from: http://www.mdw.la/papers/seda-sosp01.pdf